

Notas Metodológicas

Documento contendo todas as decisões metodológicas utilizadas no código.

Dados

LastFM-360K

- `lastfm.py`
 - Usuários que não contém nenhuma interação foram retirados | Interações sem usuário com metadados foram retiradas.
 - Artistas que não contém MBID e nem nome foram retirados.
 - Artistas sem MBID tiveram o nome encodado utilizado como ID.
 - Linhas de interações duplicadas (mesmo `user_id` e `artist_id`) foram somadas.
 - Idades não maiores do que 0 foram retiradas.
-

Interações

Métrica	Quantidade
Interações totais do dataset	17.559.530
Interações totais transformadas	17.559.021

Limpeza e Validação

Métrica	Quantidade
Linhas duplicadas agregadas	421
Artistas sem ID e nome	1
Valores de <code>play_count</code> não positivos	1
Usuários que não contém metadados	86
Idades inválidas	57

Dimensões do Dataset

Métrica	Quantidade
Quantidade de usuários	359.347
Quantidade de itens	268.602

Yelp

- `yelp.py`
 - Interações com comércios ou usuários sem metadados foram descartadas.
 - Usuários e comércios que possuem metadados mas não possuem interações foram descartados.

Observações: No Yelp dataset um mesmo usuário avaliou um mesmo comércio mais de uma vez em 212.788 interações (aproximadamente 3,15%). Total de interações é 6.990.247. Por isso, na transformação dos dados foram mantidas apenas as interações mais recentes de um mesmo par usuário-item.

Interações

Métrica	Quantidade
Interações totais do dataset	6.990.280
Interações totais transformadas	6.990.247

Limpeza e Validação

Métrica	Quantidade
Interações removidas por usuário ausente	33

Dimensões do Dataset


Métrica	Quantidade
Quantidade de usuários	1.987.897
Quantidade de itens	150.346
Usuários ativos	100.370

Critérios de Atividade

Métrica	Valor
Limiar de atividade	92
Data de referência	2022-01-19 19:48:45

Treinamento e Avaliação

Toda a pipeline de divisão de dados, validação cruzada, busca de hiperparâmetros e resultados pode ser resumida pelo seguinte fluxograma:



1. **Dados Brutos**: Dados brutos dos datasets.
2. **Dados RecBole**: Dados no formato atômico do Recbole.
- Nesta etapa, são realizados alguns filtros nos dados: ...
3. **Dados Amostrados**: Dados amostrados do resultado da transformação.
- Neste etapa, os dados são amostrados segundo os seguintes critérios: ...
4. **Dados Development**: Dados destinados para treino e validação. Representam 80% dos dados totais.
5. **Dados Teste**: Dados destinados para o teste final de generalização. Representam 20% dos dados totais.
6. **Fold i**: Um fold específico dos dados destinado a validação cruzada.
7. **Treinamento e Avaliação**: Validação cruzada, tuning de hiperparâmetros e geração de métricas dos resultados do modelo.
8. **Modelo**: Modelo treinado em cima dos **Dados de Development** (com os melhores hiperparâmetros selecionados na validação cruzada).
9. **Agrupamentos**: Divisão de grupos no dados pelos metadados dos usuários. As divisão sempre serão por cada metadado presente nos **Dados Amostrados** + divisão por K-means e Agrupamento Hierárquico.
10. **Métrica de Justiça**: Métrica de justiça calculada a partir do modelo e dos agrupamentos de usuários.

Observações:

- Todas as divisões dos dados foram feitas por usuário, ou seja, 80% dos dados para development e 20% para teste, de cada usuário. O mesmo vale para as divisões dentro dos folds.
- Para o treinamento do modelo final, foi utilizado o número de épocas equivalente a mediana das épocas da etapa de validação cruzada. Isso aconteceu porque a RecBole não faz early stopping quando a opção de validação está desativada.
- A validação cruzada serve especificamente para fazer o tuning de hiperparâmetros.