

Notas Metodológicas

Documento contendo todas as decisões metodológicas utilizadas no código.

Dados

LastFM-360K

- `lastfm.py`
 - Usuários que não contém nenhuma interação foram retirados | Interações sem usuário com metadados foram retiradas.
 - Artistas que não contém MBID e nem nome foram retirados.
 - Artistas sem MBID tiveram o nome encodado utilizado como ID.
 - Linhas de interações duplicadas (mesmo `user_id` e `artist_id`) foram somadas.
 - Idades não maiores do que 0 foram retiradas.
-

Interações

Métrica	Quantidade
Interações totais do dataset	17.559.530
Interações totais transformadas	17.559.021

Limpeza e Validação

Métrica	Quantidade
Linhas duplicadas agregadas	421
Artistas sem ID e nome	1
Valores de <code>play_count</code> não positivos	1
Usuários que não contém metadados	86
Idades inválidas	57

Dimensões do Dataset

Métrica	Quantidade
Quantidade de usuários	359.347
Quantidade de itens	268.602

Yelp

- `yelp.py`
 - Interações com comércios ou usuários sem metadados foram descartadas.
 - Usuários e comércios que possuem metadados mas não possuem interações foram descartados.

Observações: No Yelp dataset um mesmo usuário avaliou um mesmo comércio mais de uma vez em 212.788 interações (aproximadamente 3,15%). Total de interações é 6.990.247. Por isso, na transformação dos dados foram mantidas apenas as interações mais recentes de um mesmo par usuário-item.

Interações

Métrica	Quantidade
Interações totais do dataset	6.990.280
Interações totais transformadas	6.990.247

Limpeza e Validação

Métrica	Quantidade
Interações removidas por usuário ausente	33

Dimensões do Dataset


Métrica	Quantidade
Quantidade de usuários	1.987.897
Quantidade de itens	150.346
Usuários ativos	100.370

Critérios de Atividade

Métrica	Valor
Limiar de atividade	92
Data de referência	2022-01-19 19:48:45

Treinamento e Avaliação

Toda a pipeline de divisão de dados, validação cruzada, busca de hiperparâmetros e resultados pode ser resumida pelo seguinte fluxograma:



1. **Dados Brutos:** Dados brutos dos datasets.
2. **Dados RecBole:** Dados no formato atômico do Recbole.
 - Nesta etapa, são realizados alguns filtros nos dados:
 - Usuários com metadados incompletos, ou não existentes, são descartados (assim como suas interações).
 - Itens não existentes nos metadados são descartados.
 - Interações com `play_count < 0` são descartadas (no caso do LastFM).
 - Artistas sem MBID e sem nome são descartados (assim como suas interações).
3. **Dados Amostrados:** Dados amostrados do resultado da transformação.
 - São selecionados os 1.000 itens com mais interações.
 - São considerados elegíveis os usuários com pelo menos 6 interações entre os itens selecionados. Desses usuários, 1.000 são sorteados com seed 42.
 - No LastFM, o `play_count` passa pela transformação `log1p` e, em seguida, pela normalização min-max para a escala de 1 a 5. As avaliações do Yelp são preservadas.
4. **Dados Development:** Dados destinados para treino e validação.
 - Para cada usuário, correspondem às interações restantes após a separação do teste.
5. **Dados Teste:** Dados destinados ao teste final de generalização.
 - Após o embaralhamento das interações de cada usuário com seed 42, são reservadas para teste `max(1, floor(20%))` interações. Por causa do arredondamento por usuário, a proporção global pode não ser exatamente 20%.
6. **Fold i:** Um fold específico dos dados destinado à validação cruzada.
 - Apenas os dados de development participam dos folds.
 - As interações de development de cada usuário são distribuídas circularmente entre os folds, de modo que cada interação seja usada uma vez para validação. Todos os candidatos a hiperparâmetros utilizam os mesmos folds.
7. **Treinamento e Avaliação:** Validação cruzada, tuning de hiperparâmetros e geração de métricas dos resultados do modelo.
 - Os hiperparâmetros são selecionados pela média do NDCG@10 nos folds. Em caso de empate, é mantido o primeiro candidato declarado no arquivo de configuração.
 - O teste final permanece isolado durante a seleção dos hiperparâmetros e é avaliado uma única vez após a escolha do melhor candidato.
 - A avaliação é feita por full-ranking: os itens já conhecidos pelo usuário são excluídos do ranking, e todas as interações de teste são consideradas relevantes.
8. **Modelo:** Modelo treinado sobre todos os **Dados Development**, com os melhores hiperparâmetros selecionados na validação cruzada.

- O número de épocas do treinamento final é a mediana das melhores épocas obtidas nos folds. Como não há conjunto de validação nessa etapa, não é aplicado early stopping.

9. **Agrupamentos**: Divisão dos usuários em grupos por metadados e por algoritmos de agrupamento.

- No LastFM, são utilizados os grupos de gênero, idade e atividade, sendo considerados ativos os 5% de usuários com mais interações no development.
- No Yelp, são utilizados os grupos de atividade informada no perfil, quantidade de amigos e tempo de permanência na plataforma.
- K-Means e agrupamento hierárquico utilizam os atributos dos usuários e sua atividade no development. Os atributos numéricos são padronizados, e o número de grupos entre 2 e 10 é escolhido pelo maior coeficiente de silhueta.

10. **Métrica de Justiça**: Métrica de justiça calculada a partir do modelo e dos agrupamentos de usuários.

- A justiça é calculada somente sobre o teste final e não participa da seleção de hiperparâmetros.
- As predições são limitadas à escala de 1 a 5, e a perda de cada grupo é o MSE de todas as suas interações de teste. O R_{grp} mede a variação quadrática entre as perdas dos grupos.